



# Desarrollo de Algoritmos Dirigido por Retos

## Alejandro Marrero Díaz

Universidad de La Laguna

11 de julio de 2017

Escuela Superior de Ingeniería y Tecnología  
Universidad de La Laguna

- 1 Introducción
- 2 Conceptos Previos
- 3 Algoritmos Desarrollados
  - Opposition-Based Learning
  - OBL Competitive Particle Swarm Optimization
  - Covariance Matrix Adaptation Evolutionary Strategy
  - Hybrid Simulated Annealing with Global Search
- 4 Evaluación Experimental
  - Funciones Propuestas por GenOpt
  - Estudio de la Parametrización y Rendimiento
  - Comparativa de Rendimiento entre Algoritmos
  - Clasificación en el Concurso GenOpt
- 5 Conclusions and Future Work
- 6 Bibliografía

## Motivación y Objetivos

- Iniciación en el mundo de la investigación.
- Investigación en el campo de las meta-heurísticas.
- Optimización Global Continua.
- Guiar el desarrollo de todo el TFG a través de la participación en una competición de optimización global continua.

## Competiciones

- Congress on Evolutionary Computation (CEC)
- Genetic and Evolutionary Computation Conference (GECCO)
- Global Trajectory Optimisation Competition (GTOC)
- **Generalization-Based Contest in Global Optimization (GenOpt)**



# Conceptos Previos

## Definición Formal

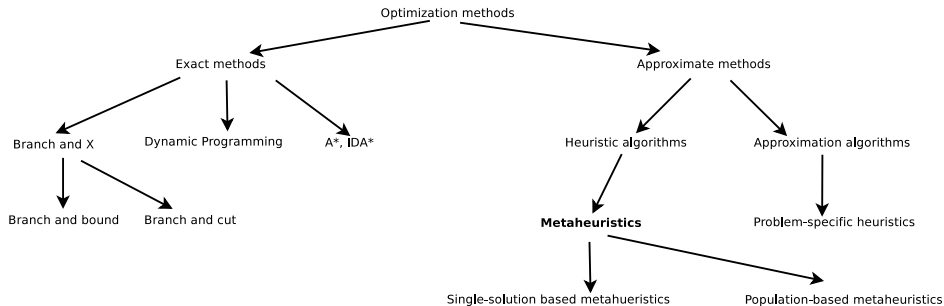
El objetivo de la optimización global, considerando un problema de minimización, es encontrar un vector  $X^* \in \Omega$  tal que  $f(X^*) \leq f(X)$  para todo  $X \in \Omega$ .

## Espacio de Búsqueda

**El espacio de búsqueda**  $\Omega$  está definido por un límite inferior ( $a_i$ ) y superior ( $b_i$ ) para cada una de las variables de decisión de la función, es decir:

$\Omega = \prod_{i=1}^D [a_i, b_i]$ , siendo  $D$  el número de variables de decisión del problema a optimizar (Segredo et al., 2017)

# Meta-heurísticas



## Categorías

- **Búsquedas Locales:** Greedy Randomized Adaptive Search Procedure (GRASP) (Díaz et al., 2017), Variable Neighborhood Search (VNS) (Hansen et al., 2010).
- **Heurísticas Voraces:** Simulated Annealing (SA) (Gerber and Bornn, 2017a).
- **Algoritmos Evolutivos:** Covariance Matrix Adaptation Evolutionary Strategy (CMA-ES) (Hajebi et al., 2016), Differential Evolution (DE) (Zheng et al., 2017; Fu et al., 2017; Tian et al., 2017), Coevolutionary Algorithms (CEA) (Atashpendar et al., 2016; Hajikolaei et al., 2016; Glorieux et al., 2016).

## Criterios de Diseño

- Representación.
  - Permutaciones.
  - Cadena binaria.
  - Vector de valores naturales.
  - **Vector de números reales.**
- Condición de parada.
  - Iteraciones.
  - Factor de error.
  - **Evaluaciones:**  $10^6$  evaluaciones establecidas por GenOpt.





# Algoritmos Desarrollados

# Opposition-Based Learning

## Definición formal

Sea  $x \in \mathbb{R}$  un número real definido dentro de un cierto intervalo:  $x \in [a, b]$ . El número opuesto de  $x$  denotado como  $\bar{x}$  se define de la siguiente forma:

$$\bar{x} = a + b - x \quad (1)$$

## Función D-Dimensional

Sea  $P(x_1, x_2, \dots, x_D)$  un punto dentro de un sistema de coordenadas  $D$  - *dimensional* con  $x_1, \dots, x_D \in \mathbb{R}$  y además  $x_i \in [a_i, b_i]$ . El opuesto del punto  $P$  se define como las coordenadas  $\bar{x}_1, \dots, \bar{x}_D$  donde:

$$\bar{x}_i = a_i + b_i - x_i \quad i = 1, \dots, D \quad (2)$$

---

**Algorithm 1** Búsqueda global()

---

```
1: NumIndividuos =  $|S|$ ;
2: OrdenarPoblacion(S);
3: MarcarNoExplorados(S);
4: Centroide = CalcularCentroide();
5: NumeroMejora = 0;
6: NumeroExplorado = 0;
7: while NumeroMejora > 0 y
   NumeroExplorado <  $|S|$  do
8:   k = 0;
9:   while  $S[k]$  = explorado y
      NumeroExplorado <  $|S|$  do
10:    k = rand(0,  $|S|$ ); (1)
11:   end while
12:    $S[k]$  = explorado;
13:   NumeroExplorado = NumeroExplorado + 1;
14:   Mejora = true;
15:   while Mejora = true do
16:     while  $|a_1| + |a_2| + |a_3| \neq 1$  do
17:       GenerarRand(a1, a2, a3); (2)
18:     end while
19:     while  $r_1 < k$  do
20:        $r_1 = \text{rand}(0, |S|)$ ; (2)
21:     end while
22:     NuevoInd = ModificarIndividuo(k, a1, a2, a3, Centroide,  $r_1$ );
23:     if NuevoInd <  $S[k]$  then
24:       Mejora = true;
25:        $S = S \cap \text{NuevoInd}$ ;
26:       NumeroMejora = NumeroMejora + 1;
27:     else
28:       Mejora = false;
29:     end if
30:   end while
31: end while
32: OrdenarPoblacion(S);
33: S = ObtenerMejores(0, NumIndividuos, S);
34: return  $|S|$  mejores individuos encontrados
```

## Diseño

El algoritmo Opposition-based Learning Competitive Particle Swarm Optimization (OBL-CPSO) (Zhou et al., 2016) incluye dos modificaciones:

- Opposition-based Learning.
- Procedimiento de Competición.

## Competición

Escogemos, aleatoriamente, tres individuos y los hacemos competir entre ellos mediante su valor de función objetivo. Para una población de tamaño  $N$ , se realizarán un total de  $N/3$  competiciones (Zhou et al., 2016).

- Ganador ( $w$ ).
- Neutro ( $n$ ).
- Perdedor ( $l$ ).

---

**Algorithm 2** OBL Competitive Particle Swarm Optimization()

---

```
1: Inicializar();
2: while Condición de parada no satisfecha do
3:   Agitar();
4:   for all  $k = 1 : N/3$  do
5:      $r_1 = S(k)$ ;
6:      $r_2 = S(k + N/3)$ ;
7:      $r_3 = S(k + 2N/3)$ ;
8:      $(w, n, l) = \text{competir}(r_1, r_2, r_3)$ ;
9:     Actualizar  $X_{ld}^k(t)$ ;
10:    Actualizar  $X_{nd}^k(t)$ ;
11:    Actualizar los valores de fitness para N y L;
12:   end for
13:   BusquedaGlobal();
14: end while
15: return Mejor solución obtenida
```

---

## Parámetros

- $\lambda$ : tamaño de la población.
- $C$ : la matriz de covarianza  $C$  de dimensión  $C_{\lambda}^D$ .
- $\sigma$ : índice de variación entre generaciones.
- $m^g \in \mathbb{R}^D$ : Valor medio de la distribución en la generación  $g$

**Algorithm 3** Covariance Matrix Adaptation Evolutionary Strategy ()**Require:**

$$m \in R^n, \sigma \in R_+, \lambda$$

1: Inicialización

$$C = I, p_c = 0, p_\sigma = 0$$

$$c_c \approx 4/n, c_\sigma \approx 4/n, c_1 \approx 2/n^2, c_\mu \approx \mu_w/n^2, c_1 + c_\mu \leq 1$$

$$d_\sigma \approx 1 + \sqrt{\frac{\mu_w}{n}}, w_i = 1 \dots \lambda \quad \text{tal que} \quad \mu_w = \frac{1}{\sum_{i=1}^{\mu} w_i^2} \approx 0,3\lambda$$

2: **while** Condición de parada no satisfecha **do**

3: Muestreo

4: Actualizar el valor medio

5: Actualizar C

6: Actualizar  $\sigma$ 

7: BúsquedaGlobal();

8: **if** Reinicio necesario **then**

9: Reiniciar();

10: **end if**11: **end while**12: **return** Mejor solución obtenida

# Hybrid Simulated Annealing with Global Search (HSAGS)

## Simulated Annealing (SA)

Simulated Annealing (SA) (Robini et al., 2017; Karagiannis et al., 2017; Gerber and Bornn, 2017b) es una meta-heurística que está inspirada por el proceso de recocido en la metalurgia (Du and Swamy, 2016).

- Iniciamos con un valor  $T_0$  muy elevado.
- Algoritmo de trayectoria (una única solución, en lugar de una población).

## Pasos del Algoritmo

- Perturbación.
- Evaluación.
- Actualizar Temperatura.
- Búsqueda global para HSAGS.



---

## Algorithm 4 Hybrid Simulated Annealing with Global Search()

---

```
1: S = GenerarSolucionAleatoria();
2: T = InicializarTemperatura();
3: while Condición de parada no satisfecha do
4:   S' = AplicarPerturbacionAleatoria(S);
5:   Dif = EvaluarDiferencia(S, S');
6:   S = ActualizarSolucion(S, S', Dif);
7:   T = ActualizarTemperatura(T);
8:   S = BusquedaGlobalSA();
9: end while
10: return Mejor solución obtenida
```

---



# Evaluación Experimental

# Funciones propuestas por GenOpt

## Características

*GenOpt* ha propuesto un total de **18 funciones** de dimensiones  $D = 10, 30$  a optimizar, realizando **cient ejecuciones independientes** para cada una de ellas.

## Familias de Funciones

- Funciones GKLS.
- Funciones Clásicas Transformadas.
  - Rastrigin.
  - Rosenbrock.
  - Zakharov.
- Funciones Compuestas.
  - Goldstein-Price.
  - Hartmann.
  - Sphere.

## Objetivos del Estudio

Determinar los mejores valores para los parámetros de cada algoritmo buscando obtener el máximo rendimiento de cada uno de ellos.

## Poblaciones

- $popsiz$  = 20, 50, 75, 100 para OBL-CPSO y CMA-ES.
- $popsiz$  = 1 para HSAGS.

# Rendimiento de OBL-CPSO

	OBL-CPSO-20			OBL-CPSO-50		
	$\mu$	$\tilde{x}$	$\sigma$	$\mu$	$\tilde{x}$	$\sigma$
$f_0$	$4,361e-01$	$2,041e-01$	$4,492e-01$	<b><math>3,937e-01</math></b>	<b><math>1,255e-01</math></b>	$4,193e-01$
$f_1$	$1,776e+00$	$1,681e+00$	$4,699e-01$	$1,464e+00$	$1,401e+00$	$2,359e-01$
$f_2$	<b><math>7,417e-01</math></b>	$1,002e+00$	$4,173e-01$	$7,657e-01$	<b><math>1,002e+00</math></b>	$3,618e-01$
$f_3$	$1,779e+00$	$1,699e+00$	$4,513e-01$	$1,455e+00$	$1,402e+00$	$2,441e-01$
$f_4$	$7,822e-01$	<b><math>1,003e+00</math></b>	$4,026e-01$	<b><math>7,764e-01</math></b>	$1,003e+00$	$3,803e-01$
$f_5$	$1,790e+00$	$1,698e+00$	$5,522e-01$	$1,451e+00$	$1,406e+00$	$2,479e-01$
$f_6$	$9,041e-01$	$3,609e-01$	$1,297e+00$	$5,852e-01$	$3,130e-01$	$7,651e-01$
$f_7$	$1,057e+01$	$1,014e+01$	$4,274e+00$	<b><math>8,992e+00</math></b>	$8,667e+00$	$3,394e+00$
$f_8$	$5,837e-01$	$3,580e-01$	$6,216e-01$	$3,908e-01$	<b><math>2,501e-01</math></b>	$4,752e-01$
$f_9$	$5,574e+00$	$5,209e+00$	$2,245e+00$	$4,881e+00$	$4,840e+00$	$1,817e+00$
$f_{10}$	$6,175e-03$	$4,830e-03$	$5,254e-03$	$4,564e-03$	$3,010e-03$	$3,711e-03$
$f_{11}$	$4,735e-02$	$4,723e-02$	$1,483e-02$	$4,155e-02$	$3,961e-02$	$1,488e-02$
$f_{12}$	$4,103e-02$	$2,806e-02$	$4,074e-02$	<b><math>2,463e-02</math></b>	<b><math>1,685e-02</math></b>	$2,296e-02$
$f_{13}$	$8,880e-02$	$8,295e-02$	$3,394e-02$	$8,708e-02$	$8,431e-02$	$2,912e-02$
$f_{14}$	$1,026e-01$	$3,233e-02$	$1,907e-01$	$3,723e-02$	$2,042e-02$	$4,753e-02$
$f_{15}$	$1,317e-01$	$1,180e-01$	$5,010e-02$	$1,198e-01$	$1,121e-01$	$3,953e-02$
$f_{16}$	$1,516e-02$	$1,252e-02$	$1,090e-02$	$1,380e-02$	$1,075e-02$	$1,142e-02$
$f_{17}$	$2,666e-01$	$2,286e-01$	$1,587e-01$	$2,049e-01$	$1,744e-01$	$1,091e-01$

# Rendimiento de OBL-CPSO

OBL-CPSO-75			OBL-CPSO-100		
$\mu$	$\tilde{x}$	$\sigma$	$\mu$	$\tilde{x}$	$\sigma$
4,095e-01	1,364e-01	4,224e-01	1,228e+00	1,218e+00	2,404e-01
<b>1,403e+00</b>	<b>1,351e+00</b>	2,047e-01	3,706e+00	3,572e+00	7,136e-01
7,968e-01	1,004e+00	3,407e-01	1,250e+00	1,227e+00	1,530e-01
<b>1,373e+00</b>	<b>1,350e+00</b>	1,722e-01	3,708e+00	3,572e+00	7,161e-01
8,439e-01	1,004e+00	3,219e-01	1,248e+00	1,216e+00	1,645e-01
<b>1,423e+00</b>	<b>1,357e+00</b>	2,284e-01	3,707e+00	3,572e+00	7,162e-01
<b>4,691e-01</b>	<b>2,570e-01</b>	4,897e-01	3,368e+00	2,636e+00	2,445e+00
9,134e+00	<b>8,482e+00</b>	3,717e+00	2,545e+01	2,466e+01	6,987e+00
<b>3,449e-01</b>	2,537e-01	3,115e-01	2,202e+00	1,999e+00	1,283e+00
<b>4,720e+00</b>	<b>4,588e+00</b>	1,643e+00	1,276e+01	1,279e+01	3,019e+00
<b>3,874e-03</b>	<b>2,688e-03</b>	3,495e-03	1,661e-02	1,440e-02	1,151e-02
<b>4,151e-02</b>	<b>3,904e-02</b>	1,285e-02	8,903e-02	8,608e-02	2,672e-02
3,093e-02	2,092e-02	3,662e-02	4,394e-01	3,230e-01	3,904e-01
<b>8,200e-02</b>	<b>8,032e-02</b>	2,643e-02	2,611e-01	2,452e-01	1,296e-01
<b>3,049e-02</b>	<b>1,543e-02</b>	4,289e-02	1,381e+00	1,147e+00	1,006e+00
<b>1,196e-01</b>	<b>1,115e-01</b>	4,406e-02	4,437e-01	3,095e-01	4,113e-01
<b>1,201e-02</b>	<b>1,052e-02</b>	8,260e-03	4,439e-02	3,137e-02	4,109e-02
<b>1,845e-01</b>	<b>1,687e-01</b>	8,040e-02	3,330e+00	2,985e+00	1,709e+00

# Rendimiento de CMA-ES

	CMA-ES-2 - 50			CMA-ES-0,3 - 50			CMA-ES-0,8 - 50		
	$\mu$	$\tilde{x}$	$\sigma$	$\mu$	$\tilde{x}$	$\sigma$	$\mu$	$\tilde{x}$	$\sigma$
$f_0$	8,503e - 01	1,000e + 00	2,677e - 01	6,503e + 00	1,089e + 00	2,677e - 01	8,503e - 01	1,000e + 00	2,677e - 01
$f_1$	1,145e + 00	1,121e + 00	9,401e - 02	1,145e + 00	1,331e + 00	9,401e - 02	1,145e + 00	1,121e + 00	9,401e - 02
$f_2$	9,650e - 01	1,000e + 00	1,102e - 01	6,890e - 01	1,120e + 00	1,102e - 01	9,650e - 01	1,000e + 00	1,102e - 01
$f_3$	1,145e + 00	1,127e + 00	9,699e - 02	1,175e + 00	1,197e + 00	9,699e - 02	1,145e + 00	1,127e + 00	9,699e - 02
$f_4$	9,568e - 01	1,000e + 00	1,375e - 01	7,544e - 01	1,000e + 00	1,375e - 01	9,568e - 01	1,000e + 00	1,375e - 01
$f_5$	1,139e + 00	1,107e + 00	9,068e - 02	2,177e + 00	1,107e + 00	9,068e - 02	1,139e + 00	1,107e + 00	9,068e - 02
$f_6$	7,098e - 03	2,675e - 03	1,102e - 02	6,068e - 03	2,895e - 03	1,102e - 02	7,098e - 03	2,675e - 03	1,102e - 02
$f_7$	3,485e + 00	3,206e + 00	1,737e + 00	4,785e + 00	3,206e + 00	1,737e + 00	3,485e + 00	3,206e + 00	1,737e + 00
$f_8$	1,114e - 02	3,920e - 03	2,502e - 02	1,184e - 02	3,500e - 03	2,502e - 02	1,114e - 02	3,920e - 03	2,502e - 02
$f_9$	1,801e + 00	1,713e + 00	8,352e - 01	2,881e + 00	1,503e + 00	8,352e - 01	1,801e + 00	1,713e + 00	8,352e - 01
$f_{10}$	2,323e - 02	2,214e - 02	2,532e - 02	1,393e - 02	2,124e - 02	2,532e - 02	2,323e - 02	2,214e - 02	2,532e - 02
$f_{11}$	5,283e - 02	5,061e - 02	1,399e - 02	3,883e - 02	5,031e - 02	1,399e - 02	5,283e - 02	5,061e - 02	1,399e - 02
$f_{12}$	2,242e - 04	1,147e - 04	5,236e - 04	4,442e - 04	1,147e - 04	5,236e - 04	2,242e - 04	1,147e - 04	5,236e - 04
$f_{13}$	3,018e - 02	2,998e - 02	7,994e - 03	2,018e - 02	2,998e - 02	7,994e - 03	3,018e - 02	2,998e - 02	7,994e - 03
$f_{14}$	1,443e - 04	2,946e - 05	3,504e - 04	1,443e - 04	2,946e - 05	3,504e - 04	1,443e - 04	2,946e - 05	3,504e - 04
$f_{15}$	4,870e - 02	4,838e - 02	1,111e - 02	4,870e - 02	4,838e - 02	1,111e - 02	4,870e - 02	4,838e - 02	1,111e - 02
$f_{16}$	9,820e - 04	2,520e - 04	5,633e - 03	9,820e - 04	2,520e - 04	5,633e - 03	9,820e - 04	2,520e - 04	5,633e - 03
$f_{17}$	3,485e - 02	3,375e - 02	9,540e - 03	3,485e - 02	3,375e - 02	9,540e - 03	3,485e - 02	3,375e - 02	9,540e - 03

# Rendimiento de HSAGS

	HSAGS-500		HSAGS-1000		HSAGS-10000
$f_0$	$8,060e - 01$	$\leftrightarrow$	<b>9.338e-01</b>	$\leftrightarrow$	$7,384e - 01$
$f_1$	<b>0,000e + 00</b>		$9,732e - 01$	$\leftrightarrow$	$9,732e - 01$
$f_2$	$9,241e - 01$	$\leftrightarrow$	$9,270e - 01$	$\leftrightarrow$	<b>9.711e-01</b>
$f_3$	<b>0,000e + 00</b>		<b>0,000e + 00</b>		<b>0,000e + 00</b>
$f_4$	$7,369e - 01$	$\leftrightarrow$	<b>8.174e-01</b>	$\leftrightarrow$	$5,917e - 01$
$f_5$	$9,481e - 01$	$\leftrightarrow$	$9,460e - 01$	$\leftrightarrow$	<b>9.978e-01</b>
$f_6$	$9,961e - 01$	$\leftrightarrow$	$9,971e - 01$	$\leftrightarrow$	<b>9.990e-01</b>
$f_7$	<b>9.990e-01</b>	$\leftrightarrow$	$9,971e - 01$	$\leftrightarrow$	$9,981e - 01$
$f_8$	<b>0,000e + 00</b>		$1,000e + 00$	$\leftrightarrow$	$1,000e + 00$
$f_9$	$1,000e + 00$	$\leftrightarrow$	$1,000e + 00$	$\leftrightarrow$	<b>0,000e + 00</b>
$f_{10}$	<b>9.990e-01</b>	$\leftrightarrow$	$9,971e - 01$	$\leftrightarrow$	$9,981e - 01$
$f_{11}$	$9,942e - 01$	$\leftrightarrow$	$9,961e - 01$	$\leftrightarrow$	<b>9.990e-01</b>
$f_{12}$	<b>1.000e+00</b>	$\leftrightarrow$	$1,000e + 00$	$\leftrightarrow$	$1,000e + 00$
$f_{13}$	<b>9.990e-01</b>	$\leftrightarrow$	$9,990e - 01$	$\leftrightarrow$	$1,000e + 00$
$f_{14}$	<b>1.000e+00</b>	$\leftrightarrow$	$1,000e + 00$	$\leftrightarrow$	$1,000e + 00$
$f_{15}$	<b>1.000e+00</b>	$\leftrightarrow$	$1,000e + 00$	$\leftrightarrow$	$1,000e + 00$
$f_{16}$	$1,000e + 00$	$\leftrightarrow$	<b>9.990e-01</b>	$\leftrightarrow$	$9,990e - 01$
$f_{17}$	<b>1.000e+00</b>	$\leftrightarrow$	$1,000e + 00$	$\leftrightarrow$	$1,000e + 00$



# Comparativa de Rendimiento entre Algoritmos

## Objetivos del Estudio

Comparar el rendimiento de cada uno de los algoritmos a la hora de optimizar las funciones propuestas por GenOpt.

# Comparativa de Rendimiento entre Algoritmos

	CMA-ES-2 - 50			OBL-CPSO-75			HSAGS-500		
	$\mu$	$\bar{x}$	$\sigma$	$\mu$	$\bar{x}$	$\sigma$	$\mu$	$\bar{x}$	$\sigma$
$f_0$	$8,503e-01$	$1,000e+00$	$2,677e-01$	<b><math>4,095e-01</math></b>	<b><math>1,364e-01</math></b>	$4,224e-01$	$3,875e+00$	$3,731e+00$	$8,967e-01$
$f_1$	<b><math>1,145e+00</math></b>	<b><math>1,121e+00</math></b>	$9,401e-02$	$1,403e+00$	$1,351e+00$	$2,047e-01$	$1,065e+01$	$1,052e+01$	$1,439e+00$
$f_2$	<b><math>9,650e-01</math></b>	<b><math>1,000e+00</math></b>	$1,102e-01$	$7,968e-01$	$1,004e+00$	$3,407e-01$	$3,878e+00$	$3,731e+00$	$8,982e-01$
$f_3$	<b><math>1,145e+00</math></b>	<b><math>1,127e+00</math></b>	$9,699e-02$	$1,373e+00$	$1,350e+00$	$1,722e-01$	$1,065e+01$	$1,052e+01$	$1,439e+00$
$f_4$	<b><math>9,568e-01</math></b>	<b><math>1,000e+00</math></b>	$1,375e-01$	$8,439e-01$	$1,004e+00$	$3,219e-01$	$9,568e-01$	$1,000e+00$	$1,375e-01$
$f_5$	<b><math>1,139e+00</math></b>	<b><math>1,107e+00</math></b>	$9,068e-02$	$1,423e+00$	$1,357e+00$	$2,284e-01$	$1,064e+01$	$1,050e+01$	$1,435e+00$
$f_6$	<b><math>7,098e-03</math></b>	<b><math>2,675e-03</math></b>	$1,102e-02$	$4,691e-01$	$2,570e-01$	$4,897e-01$	$1,373e+01$	$1,227e+01$	$6,326e+00$
$f_7$	<b><math>3,485e+00</math></b>	<b><math>3,206e+00</math></b>	$1,737e+00$	$9,134e+00$	$8,482e+00$	$3,717e+00$	$4,560e+01$	$4,423e+01$	$1,053e+01$
$f_8$	$1,114e-02$	<b><math>3,920e-03</math></b>	$2,502e-02$	$3,449e-01$	$2,537e-01$	$3,115e-01$	$6,038e+00$	$6,183e+00$	$1,809e+00$
$f_9$	<b><math>1,801e+00</math></b>	<b><math>1,713e+00</math></b>	$8,352e-01$	$4,720e+00$	$4,588e+00$	$1,643e+00$	$1,903e+01$	$1,891e+01$	$3,118e+00$
$f_{10}$	<b><math>2,323e-02</math></b>	<b><math>2,214e-02</math></b>	$2,532e-02$	$3,874e-03$	$2,688e-03$	$3,495e-03$	$1,270e-01$	$5,255e-02$	$2,558e-01$
$f_{11}$	<b><math>5,283e-02</math></b>	<b><math>5,061e-02</math></b>	$1,399e-02$	$4,151e-02$	$3,904e-02$	$1,285e-02$	$4,264e+00$	$1,808e-01$	$2,459e+01$
$f_{12}$	<b><math>2,242e-04</math></b>	<b><math>1,147e-04</math></b>	$5,236e-04$	$3,093e-02$	$2,092e-02$	$3,662e-02$	$5,330e+00$	$5,016e+00$	$2,499e+00$
$f_{13}$	<b><math>3,018e-02</math></b>	<b><math>2,998e-02</math></b>	$7,994e-03$	$8,200e-02$	$8,032e-02$	$2,643e-02$	$2,689e+00$	$2,567e+00$	$1,265e+00$
$f_{14}$	<b><math>1,443e-04</math></b>	<b><math>2,946e-05</math></b>	$3,504e-04$	$3,049e-02$	$1,543e-02$	$4,289e-02$	$8,964e+00$	$8,338e+00$	$4,235e+00$
$f_{15}$	<b><math>4,870e-02</math></b>	<b><math>4,838e-02</math></b>	$1,111e-02$	$1,196e-01$	$1,115e-01$	$4,406e-02$	$1,009e+01$	$8,802e+00$	$5,327e+00$
$f_{16}$	<b><math>9,820e-04</math></b>	<b><math>2,520e-04</math></b>	$5,633e-03$	$1,201e-02$	$1,052e-02$	$8,260e-03$	$4,049e+00$	$3,340e+00$	$3,172e+00$
$f_{17}$	<b><math>3,485e-02</math></b>	<b><math>3,375e-02</math></b>	$9,540e-03$	$1,845e-01$	$1,687e-01$	$8,040e-02$	$1,603e+01$	$1,465e+01$	$5,702e+00$

## Criterios de Clasificación de GenOpt

- **High Jump**: mejor valor obtenido en los puntos de control.
- **Target Shooting**: éxito a la hora de alcanzar el óptimo global de la función.
- **Biathlon Score**: media entre el High Jump y Target Shooting.

---

<sup>1</sup>Manifiesto del concurso GenOpt: <http://www.genopt.org/genopt.pdf>.

# Clasificación en el Concurso GenOpt



# Conclusions and Future Work

## Conclusions

- High amount of parameters increases the complexity to evaluate the performance of the algorithms.
- The task of assessing a new modification was really difficult.
- CMA-ES algorithm accomplished the **third place** in the final leaderboard of the GenOpt contest considering the High Jump criterion.

## Future Work

- Improve the different tested algorithms.



¿Preguntas?  
Gracias por su atención.

- Atashpendar, A., Dorronsoro, B., Danoy, G., and Bouvry, P. (2016). A parallel cooperative coevolutionary smmpso algorithm for multi-objective optimization. pages 713–720.
- Du, K.-L. and Swamy, M. N. S. (2016). *Search and Optimization by Metaheuristics*.
- Díaz, J., Luna, D., Camacho-Vallejo, J.-F., and Casas-Ramírez, M.-S. (2017). Grasp and hybrid grasp-tabu heuristics to solve a maximal covering location problem with customer preference ordering. *Expert Systems with Applications*, 82:67–76.
- Fu, C., Jiang, C., Chen, G., and Liu, Q. (2017). An adaptive differential evolution algorithm with an aging leader and challengers mechanism. *Applied Soft Computing Journal*, 57:60–73.
- Gerber, M. and Bornn, L. (2017a). Improving simulated annealing through derandomization. *Journal of Global Optimization*, 68(1):189–217.
- Gerber, M. and Bornn, L. (2017b). Improving simulated annealing through derandomization. *Journal of Global Optimization*, 68(1):189–217.
- Glorieux, E., Svensson, B., Danielsson, F., and Lennartson, B. (2016). Improved constructive cooperative coevolutionary differential evolution for large-scale optimisation. pages 1703–1710.
- Hajebi, M., Hoorfar, A., and Bou-Daher, E. (2016). Inverse profiling of inhomogenous buried cylinders with arbitrary cross sections using cma-es. pages 863–864.
- Hajikolaie, K., Cheng, G., and Wang, G. (2016). Optimization on metamodeling-supported iterative decomposition. *Journal of Mechanical Design, Transactions of the ASME*, 138(2).

# Bibliografía (cont.)

- Hansen, P., Mladenović, N., and Moreno Pérez, J. A. (2010). Variable neighbourhood search: methods and applications. *Annals of Operations Research*, 175(1):367–407.
- Karagiannis, G., Konomi, B., Lin, G., and Liang, F. (2017). Parallel and interacting stochastic approximation annealing algorithms for global optimisation. *Statistics and Computing*, 27(4):927–945.
- Robini, M., Ozon, M., Frindel, C., Yang, F., and Zhu, Y. (2017). Global diffusion tractography by simulated annealing. *IEEE Transactions on Biomedical Engineering*, 64(3):649–660.
- Segredo, E., Paechter, B., Segura, C., and González-Vila, C. I. (2017). On the comparison of initialisation strategies in differential evolution for large scale optimisation. *Optimization Letters*, pages 1–14.
- Tian, M., Gao, X., and Dai, C. (2017). Differential evolution with improved individual-based parameter setting and selection strategy. *Applied Soft Computing Journal*, 56:286–297.
- Zheng, L., Zhang, S., Tang, K., and Zheng, S. (2017). Differential evolution powered by collective information. *Information Sciences*, 399:13–29.
- Zhou, J., Fang, W., Wu, X., Sun, J., and Cheng, S. (2016). An Opposition-Based Learning Competitive Particle Swarm Optimizer. pages 515–521.





# Desarrollo de Algoritmos Dirigido por Retos

Alejandro Marrero Díaz

Universidad de La Laguna

11 de julio de 2017

Escuela Superior de Ingeniería y Tecnología  
Universidad de La Laguna